🏆 Top Ten: Die wichtigsten Erkenntnisse der KI-Diskussionswoche

Destilliert aus den Vorträgen und Diskussionen der Woche für Wissenschaftler:innen und Mitarbeitende der Forschungsverwaltung.

---

1. 🔬 Evidenz statt Hype — Messen statt Behaupten

Aussagen über die Leistung von KI sind Behauptungen, bis sie gemessen sind. Im Roboterfußball-Projekt wird jedes KI-Verhalten über automatisierte Qualitätskontrolle per Kennzahlen und eingefrorene Vergleichsbaselines geprüft; unbelegte Aussagen werden bereits bei der Dokumentation als unverifiziert markiert. Was nicht belegt ist, gilt nicht — eine Kultur, die auf jedes Forschungs- und Verwaltungsprojekt übertragbar ist.

- **Versionierte Wissensbasis in Markdown als „Single Source of Truth"**: Architektur-Entscheidungen, Regeln und Fehlerkataloge liegen im Projektarchiv — nicht in Wikis, die niemand liest.
- **KI-gegen-KI-Review**: Eine erste Prüfung durch ein zweites Modell deckt zusätzliche Fehler auf — die manuelle Prüfung bleibt anschließend unverzichtbar.

2. 🧩 Mikro-Tasking — Kleine Schritte, große Wirkung

Komplexe Aufgaben in sequenzierbare Teilprobleme zu zerlegen senkt Kosten und Fehlerquoten zugleich — vom Roboterfußball bis zur Extraktion von Schulbezirkssatzungen in Sachsen. Kleine Modelle profitieren enorm von spezialisierten Pipelines; oft ist die geschickte Zerlegung wichtiger als der Einsatz eines größeren Modells.

- **Reduzierter Ressourcenverbrauch**: Die Zerlegung verringert Anfragegrößen und Antwortzeiten — und damit die laufenden Kosten.
- **Laufzeit pro Teilschritt nachrangig**: Bei der Satzungs-Extraktion zählte Genauigkeit, nicht Geschwindigkeit — die Zerlegung machte das Problem überhaupt erst zuverlässig lösbar.

3. 📚 Beispiele schlagen Regeln — Few-Shot-Prompting überzeugt

Sprachmodelle lernen durch konkrete Beispiele deutlich besser als durch abstrakte Anweisungen. Im Roboterfußball brachte ein Beispiel-Block im Prompt eine drastisch verbesserte Trefferquote, während Regel-Formulierungen nahezu wirkungslos blieben — eine Erkenntnis, die sich domänenübergreifend bestätigte.

- **„Take your time"**: Dem Modell ausreichend Zeit einräumen statt schnelle Antworten zu erzwingen — die Qualität steigt deutlich, und paradoxerweise sinkt die Gesamtbearbeitungszeit oft durch weniger Iterationen.
- **Begriffliche Kalibrierung**: Kleine Modelle verstehen nur Begriffe aus ihren Trainingsdaten — systematisch testen, welche Formulierungen tatsächlich ankommen.
- **Prompting als strukturierter Dialog** mit Kontext, Formatvorgaben und Beispielen — nicht als einmalige Befehlseingabe.

4. 🎓 Aufbaubar statt kaufbar — KI-Kompetenz durch Verantwortung

KI-Kompetenz entsteht nicht durch das Bedienen von Chatbots, sondern durch das verantwortungsvolle Steuern, Prüfen und Nachvollziehen von Methoden und Ergebnissen über den gesamten Projektlebenszyklus. Reine Bedienungsfähigkeiten verlieren am Arbeitsmarkt rapide an Wert — Lehrende und Fachkräfte bleiben unersetzbar, die KI ist Teammitglied, kein Ersatz.

- **Agentenbasierte Einarbeitung**: Neue Teammitglieder werden vom Agenten selbst eingearbeitet; kurze Anleitungen (Cheat Sheets) erweisen sich als wirksamer als Handbücher. Der Agent führt sein Gedächtnis in Markdown-Dateien, die er selbst liest und erweitert.
- **OpenClaw-Session**: Auf die Bitte um eine Willkommensrede fragte der Agent nach dem gewünschten Format, merkte sich den Kanal und lieferte die Rede auf Französisch — anschließend als Audio und Video. Der Agent als Dialogpartner, nicht als Ein-Schritt-Generator.
- **Kollegial sammeln statt doppelt arbeiten**: Prompt-Bibliotheken und Kontexte über gemeinsame Plattformen teilen.

5. 🏠 Local-first — Datenhoheit durch lokale Infrastruktur

Lokal betriebene Modelle schaffen Datenhoheit ohne Abhängigkeit von externen Anbietern; die Grenzkosten pro Anfrage sinken auf den Energieverbrauch. Bei sensiblen oder vertraulichen Daten — in der Forschung wie in der Verwaltung — sind lokale Lösungen oft die einzige konforme Option. Die technische Umsetzbarkeit wurde in mehreren Projekten der Woche demonstriert.

- **Isolierte Ausführung**: Ein Agent lieferte von einem USB-Live-Stick mit deaktivierter interner Festplatte; der Zugriff auf Arbeitsordner erfolgte über ein gemountetes Netzlaufwerk, Installationen und Internetzugriffe nur nach expliziter Freigabe (Whitelist-Prinzip).
- **Betrieb in abgeschotteten Containern** ohne Internetzugriff — keine vertraulichen Daten an externe Schnittstellen.

- **Zugriff überall**: Steuerung über Browser, Desktop-Anwendung oder Messenger — auch remote.

6. 💸 Transparente Kosten — Iterationsschleifen im Blick behalten

Schnelle, günstige Antworten bedeuten nicht automatisch kosteneffiziente Ergebnisse: Jede Nachfrage, jede Korrekturschleife und jeder beauftragte Sub-Agenten-Aufruf erhöht den Verbrauch — oft unsichtbar in der Oberfläche. In der Praxis benötigt bis zur Hälfte der Ergebnisse manuelle Nacharbeit. Die Abrechnung erfolgt nach Token-Anzahl, nicht nach tatsächlicher Serverlast, was echte Intransparenz schafft.

- **Auto-Router als Geldhebel**: Weiterleitungsdienste (z. B. OpenRouter) wählen automatisch kostengünstige Modelle für qualitätsunabhängige Aufgaben; Freischaltung in Sekunden, Rabattaktionen („Deal of the Month") und kostenlose Kontingente großer Hersteller (z. B. Nvidia) eignen sich für Testphasen.
- **Proxy-Schicht für produktive Umgebungen**: bündelt mehrere Anbieter, bietet Ausfall-Ausweichlogik und zentrale Kostenkontrolle.
- **Empfehlung**: eine zentrale Steuerungsebene, die organisationsweit Standards, Tool-Empfehlungen und Kostenrichtlinien vorgibt.
- **Offen geblieben**: Die Orchestrierung durch Multi-Agenten-Systeme endete ohne pauschales Fazit — je nach Anwendungsfall sinnvoll oder ineffizient.

7. 📊 Benchmarks als Filter — Das eigene Setup entscheidet

Die Auswahl von Anbietern und passenden Modellen ist eine komplexe Aufgabe: Leaderboards liefern eine erste Orientierung, doch die Praxisleistung hängt vom konkreten Anwendungsfall, vom Prompting und vom Gesamtsetup ab. Selbst top-bewertete Modelle benötigen Anpassung, Tests und manuelle Nachbearbeitung.

- **Der Werkzeugmarkt ist ebenso volatil**: OpenCode wurde als stabiles, aktiv entwickeltes Werkzeug empfohlen; Continue befand sich in früher Alpha und wurde verworfen; Kilo Code wurde nicht mehr gepflegt — ein Fehler kürzte Dateinamen ab und erzeugte so doppelte Dateien.
- **Etablierter Standard**: VS Code mit GitHub Copilot im täglichen Einsatz.
- **Empfehlung**: Benchmarks als Startpunkt nutzen — die Entscheidung aber erst nach eigenen Tests im eigenen Setup treffen.

8. 🧹 Daten vor KI — Aufbereitung vor Automatisierung

Die Datenbereinigung beansprucht 30–50 % der Projektzeit. KI hilft vor allem dort, wo noch keine strukturierte Basis existiert — aber die Qualität steht und fällt mit der Datenpipeline, nicht mit der Modellwahl.

- **Schulbezirks-Extraktion in Sachsen**: Die Konvertierung natürlichsprachiger Satzungen nach Markdown brachte deutlich bessere Ergebnisse als die Nutzung roher OCR-Texte, weil Strukturmerkmale (Überschriften, Absätze) erhalten blieben.
- **Ensemble-Verfahren schlugen aufwendigere Verfeinerung**: Mehrfaches Durchlaufen zur Plausibilisierung war erfolgreicher als komplizierte Refinement-Ansätze.
- **Algorithmische Ausgabe statt Freitext**: Die strukturierte Ausgabe (JSON) wurde algorithmisch erzeugt statt vom Modell schreiben zu lassen — schneller und frei von Syntaxfehlern.
- **Einordnung**: Viele Verwaltungen wünschen sich eine KI-Lösung, wo ein einfaches Suchsystem ausreichen würde — zunächst den tatsächlichen Bedarf klären.
- **Offen geblieben**: Die optimale Zerlegung von Dokumenten für die Suche (Chunking, Vektorraumgröße) — hier gab es keine pauschale Antwort.

9. 🐇 Klein schlägt Groß — Spezialisierung vor Generalisierung | Konsens der Verwaltungsrunde

Konsens der Verwaltungsdiskussion: Der Glaube, allgemeine Sprachmodelle könnten komplexe Verwaltungs- und Fachaufgaben allein lösen, ist illusorisch. Erfolg entsteht durch Domänenfokus — spezialisierte, fein abgestimmte oder destillierte kleine Modelle und robuste Datenpipelines statt teurer Universal-Neuentwicklungen.

- **Spark Workflow** (Bundesinnenministerium): Open-Source-Lösung zur KI-gestützten Antragsbearbeitung, Pilotierung läuft.
- **F13** (Baden-Württemberg): eigenes Open-Source-Frontend — der Mehrwert gegenüber etablierten Community-Tools blieb jedoch unklar.
- **Distillation**: aufgabenspezifische Fähigkeiten großer Modelle in kleine, spezialisierte Modelle überführen — ideal für Lehre und ressourcenbeschränkte Umgebungen.
- **Konsens der Robotikrunde**: Mixture-of-Experts-Modelle unverzüglich erproben — Qualität eines großen Modells bei der Rechenlast eines kleinen.

10. 🤵 Human in Command — Der Mensch entscheidet

Sprachmodelle sind Wahrscheinlichkeitsmaschinen ohne intrinsisches Weltwissen: Halluzinationen sind strukturell bedingt, Ergebnisse müssen stets validiert werden. Vollautomatisierte Verwaltungsakte bleiben nach geltendem Recht die Ausnahme; die EU-KI-Verordnung macht Behörden zu Betreibern mit Dokumentations- und Bewertungspflichten. KI entwirft — der Mensch entscheidet.

- **Prompt-Injection live vorgeführt**: Eine per Copy-Paste eingeschmuggelte Fiktion stand unsichtbar im Kontext und verfälschte die Ergebnisse — Eingabequellen grundsätzlich validieren.

- **Git-Workflow mit Schlusskontrolle**: Die KI schlägt Branches und Commit-Messages vor; Merge-Requests unterliegen immer der manuellen Prüfung — die KI arbeitet maximal bis zur Commit-Message.
- **Getrennte Arbeitsmodi**: Planen (nur lesen und analysieren) und Bauen (ändern und ausführen) — der Wechsel ist eine bewusste Freigabe des Menschen. Erst denken, dann bauen.
- **Neue Governance-Frage**: KI-gestützte Suche macht historisch verschüttete, nicht-öffentliche Dokumente auffindbar — granulare Zugriffsrechte werden nötig, verwaltungsrechtlich noch klärungsbedürftig.
- **Offen geblieben**: „Wann hört der Agent auf?" — es existiert kein inhärentes Ende-Kriterium. Die Diskussion zwischen kontrollierter (europäischer) und autonomer (amerikanischer) Agenten-Philosophie endete ohne Einigung.

Kernbotschaft der Woche: KI ist kein Selbstläufer, sondern ein messbares, spezialisiertes Werkzeug — ihr Wert entsteht durch Zerlegung in Teilaufgaben, evidenzbasierte Evaluation, transparente Kostensteuerung und menschliche Letztverantwortung.